Essay of DeepXplore

2022480012 우지성

사용 모델

Model1 : Resnet50 기반의 CIFAR10 가중치 모델 (https://github.com/kusiwu/Resnet50-Cifar10-Python-Keras)

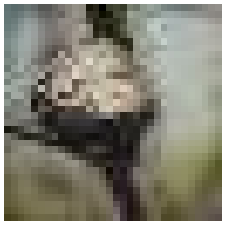

Model2,3 : (ImageNet Resnet50을 Dropout 적용 유무를 달리 FineTunning)

실험 결과

Testing이 진행될수록 Neuron Coverage의 활성화 정도가 상승함을 알 수 있다. Scratch부터 Cifar10을 대상으로 학습하여 정확도가 높았던 1번에 비해 파인튜닝을 하여 정확도가 낮은 축에서 종료한 2,3번 신경망의 뉴런 커버리지가 비교적 낮았다.

```
covered neurons percentage 55181 neurons 0.524, 91341 neurons 0.500, 93389 neurons 0.490
averaged covered neurons 0.501
input already causes different outputs: cat, truck, dog
covered neurons percentage 55181 neurons 0.531, 91341 neurons 0.513, 93389 neurons 0.502
averaged covered neurons 0.513
input already causes different outputs: cat, horse, horse
covered neurons percentage 55181 neurons 0.548, 91341 neurons 0.532, 93389 neurons 0.522
averaged covered neurons 0.532
input already causes different outputs: cat, frog, frog
covered neurons percentage 55181 neurons 0.555, 91341 neurons 0.545, 93389 neurons 0.534
averaged covered neurons 0.543
input already causes different outputs: bird, truck, automobile
covered neurons percentage 55181 neurons 0.560, 91341 neurons 0.559, 93389 neurons 0.548
averaged covered neurons 0.555
input already causes different outputs: frog, automobile, truck
covered neurons percentage 55181 neurons 0.567, 91341 neurons 0.569, 93389 neurons 0.558
averaged covered neurons 0.564
```

이는 연산 Epoch와 관련하여, 수렴점까지 학습을 시키지 못했음과도 연관이 있을 것이다. 조금 더 탐색범위를 학습하지 못한 2,3번 모델이, CIFAR10에 대해 정확히 인식하고 있는 1번 모델에 비해 더 적은 수의 뉴런 커버리지는 지닌다는 것을 알 수 있다.

Discussion

1. Synergies

   PGD가 제한된 비용으로 Decision Boundary로 가까이 가는 만큼, 이를 응용하여 검증에 사용하는 DeepXplore은 이러한 악의적인 Perturbation에 가까운 데이터를 생성해낼 수 있다.
   따라서, 기존 무작위 Pertubation을 도입하여 이미지의 Robust를 테스팅하는 방식에 비해, Whitebox Attack 기법을 채용하여 테스팅하는 것이, 좀 더 강력한 Robustness Method이며, 검증에 걸리는 시간을 굉장히 줄여주는 이점이 있다.

2. Coverage-Guided Attacks

   또한, 해당 방식을 수행하기 위해 Neuron Coverage를 공격의 Metric으로 측정하였다. 기존 손실함수 기반의 Gradient Descent 방식은, '개선이 될 수 없는' 데이터에 집착을 하는 경향이 존재 할 것이다. 특정 neuron에 크게 의존적인 오류 데이터는 테스팅에 성공하여도 이를 해결하기엔 굉장히 어렵기에, 이를 해결하기 위한 지표이기도 하다.
   앞에 문제를 해결하기 위해, Neuron Coverage를 고려하게된다면, Gradient가 줄어들진 않지만, 다양한 Neuron이 개입할 수 있는 데이터로서 검증을 시작하게되는데, 이는 발견하였을 시, 해당 데이터를 통해 학습을 진행하게 된다면, 훨씬 좋은 학습이 가능하게된다.

3. Efficiency

   1번에서도 언급되었으나, 두 목적함수를 함께 이용하는 것은, 굉장히 효율적인 탐색 효율성을 가져올 수 있게 된다. 탐색하지 않았으나, Loss가 진행을 희망하는 방향의 반대로 이동하는 데이터가

일종의 Local Minimum 문제에 당착하게 만들 수 있는데, 이 때 Neuron Coverage를 이용하면 훨씬 좋은 탐색성능을 지닐 수 있게 될 것이며, 이러한 미탐색된 부분을 찾아낸다는 점은, 좀 더 균일하게 기울기를 계산할 수 있다는 의미이다.

4. Limitations

하지만 해당 방법론에는 한계가 존재하는데, 바로 Neuron Coverage라는 지표의 한계이다. 학기 중에도 다루었으나, Neuron Coverage라는 지표 자체가 정말 좋은 것인지에 대한 의문이 존재한다. 다양한 신경망은, 신경망 모듈 내부에 일종의 분업이 존재하며, 이는 LLM의 전문가 영역의 비유로 알 수 있을 것이다. 특정한 데이터에 대한 결정영역은, 특정한 뉴런이 담당하고 있음을 알 수 있는데, 해당 영역에서 비활성화 된 뉴런이 정말 '덜 탐색된' 영역인지에 대한 문제가 존재할 것이다. 뉴런이 활성화되지 않았다는 것은 단순히 덜 탐색되었기 때문이 아니라, 뉴런이 비활성화되었음이 일종의 Signal로 작용하여 대규모 신경망의 창발을 일으키는 수단일 수 있기 때문이다.또한 해당 Loss Function은 Explore과 Exploit의 균형을 맞춘다고 볼 수 있을텐데, 둘의 균형이 무너졌을 때의 문제도 존재할 것이다. 너무 Loss Function의 감소만을 적대적 샘플 생산의 지표로서 활용한다면, 이는 일종의 과집중의 문제를 야기할 것이며, 그렇다고 너무 뉴런의 활성화정도만을 지표로 따진다면, 명백한 Loss로서 취약한 부분을 넘어가고 미탐색된 부분에 과집착하는 현상이 보일 수 있다. 또한 해당 방식은 모든 신경망의 뉴런이 활성화되었는지를 측정하기에, 신경망의 파라미터수가 커질수록 굉장히 느려지게 되는 것도 문제가 될 것이다.